

PROYECTO 2: Gestión de Metadatos y Ciclo de Vida del Dato

Tarea 1. Creación de repositorio de metadatos

El proceso de **Gestión de Metadatos** en EnergiTech tiene como objetivo principal eliminar la ambigüedad en el uso de la información a través de los silos organizacionales. Para ello, se han desarrollado tres repositorios interconectados que documentan el conocimiento de negocio, técnico y operativo de la compañía.

1.1. Creación de la Infraestructura

Se ha decidido crear un contenedor para usar OpenMetadata de forma local para la práctica. A su vez se añadirán dos bases de datos (Postgress y MySQL) que se conectarán a OpenMetadata en puertos diferentes. También se creará un script de creado de tablas y de inserción de datos sintéticos. Todos los archivos necesarios para replicar la infraestructura y los datos utilizados se dejan a disposición en el repositorio de este trabajo.

- **Tecnología:** Docker Compose.
- **Servicios:**
 - **OpenMetadata Stack:** Para el glosario, catálogo y linaje.
 - **MySQL (Puerto 3306):** Base de Datos Comercial (Silo Comercial).
 - **PostgreSQL (Puerto 5432):** Silo Técnico/IoT.
- **Datos Sintéticos:** Se ha desarrollado un script SQL que genera 100 registros en las tablas *Clientes*, *Sensores* y *Telemetría* para permitir el perfilado de datos en la herramienta.

1.2. Estructura de los Repositorios de Metadatos

EnergiTech ha implementado los siguientes instrumentos de documentación de metadatos:

1. **Glosario de Términos (Metadatos de Negocio):** Centraliza las definiciones semánticas y reglas de negocio. Su objetivo es que todos los empleados y activos de la empresa compartan el mismo significado de los conceptos.
2. **Catálogo de Datos (Metadatos Operativos):** Documenta el "linaje" y la procedencia de los datos. Indica quién es el responsable (Data Owner), con qué frecuencia se actualiza el dato y cuál es su nivel de sensibilidad.
3. **Diccionario de Datos (Metadatos Técnicos):** Detalla la implementación física en las bases de datos. Incluye nombres de tablas, tipos de datos (decimal, varchar), claves primarias y restricciones de integridad.

1.3. Análisis de Herramientas Software para la gestión de Metadatos

Se han evaluado varias herramientas que ofrecen soluciones para la gestión de los metadatos de Energitech. Entre las herramientas analizadas destacan **Collibra**, por su robustez en la gestión de glosarios de negocio, y **Apache Atlas**, por su enfoque en el linaje técnico en entornos Big Data.

Tras un análisis comparativo, se ha seleccionado **OpenMetadata** como la plataforma central para la estrategia de datos. Se ha elegido porque es una herramienta unificada para la gestión, es capaz de gestionar los 3 tipos de metadatos de Energitech en un solo lugar. A diferencia de otras herramientas, OpenMetadata ofrece conectores que automatizan la ingesta de metadatos desde las bases de datos relacionales de la compañía, reduciendo el mantenimiento manual y garantizando que el glosario de términos esté siempre vinculado a la implementación física del dato.

A continuación, se explican las funcionalidades que ofrece la herramienta seleccionada para cada tipo de metadato y un ejemplo de aplicación para la empresa:

Tipo de Metadato	Funcionalidad	Aplicación en la Energitech
Negocio	Glossary & Classification	Permite definir términos como "Cliente Residencial" o "Potencia Contratada", estableciendo reglas de negocio y etiquetas de clasificación que son visibles para toda la organización.
Técnico	Automated Profiling & Ingestion	Extrae automáticamente los esquemas de las tablas, identificando tipos de datos, claves primarias y permitiendo la creación de un diccionario técnico actualizado en tiempo real.
Operativo	Lineage & Ownership	Registra el origen del dato y su flujo desde los Smart Meters hasta los informes de previsión. Permite asignar roles (Data Owners) y monitorizar la frecuencia de actualización de las ingestas IoT.

1.4. Trazabilidad y Relaciones entre Metadatos

Uno de los requisitos críticos de EnergiTech es garantizar la trazabilidad. A continuación, se presenta un ejemplo de cómo se relacionan los tres tipos de metadatos para la trazabilidad del término **"Consumo de Energía"**:

Metadato de Negocio (Glosario):

- Término: Consumo de Energía Activa.
- Definición: Cantidad de electricidad real consumida por un cliente en un intervalo de 15 minutos, expresada en kWh.
- Regla: Debe ser un valor acumulado positivo.

Metadato Operativo (Catálogo):

- Origen: Sensores Smart Meters (Red IoT).
- Data Owner: Jefe de Redes Inteligentes.
- Frecuencia: Cada 15 minutos.

Metadato Técnico (Diccionario):

- Nombre Físico: Kw_consumidos
- Tipo: Decimal (10,3)
- Tabla: Telemetría_IoT
- Base de Datos: Data Lake

Tarea 2. Gestión de ciclo de vida del dato

El ciclo de vida del dato es un flujo continuo que garantiza que los datos de los sensores IoT se conviertan en información de valor que ayude a la toma de decisiones de la empresa . Se ha diseñado un flujo básico que permite rastrear el dato desde su origen hasta su archivado o eliminación.

2.1. Flujo de Procesamiento del Dato

El flujo se ha estructurado en cuatro etapas diferenciadas, centradas en el dato de **telemetría de consumo**, por ser el activo más importante para la previsión de demanda:

Etapa	Descripción
Ingesta	Captura de datos en formato bruto desde los sensores IoT y las APIs meteorológicas.
Transformación	Limpieza, normalización y aplicación de reglas de negocio para convertir el dato bruto en información útil.
Almacenamiento	Persistencia del dato ya procesado en estructuras optimizadas para la consulta analítica rápida.
Explotación	Consumo del dato por parte de los modelos de IA de previsión y dashboards de visualización para negocio.

2.2. Controles de Validación en la Fase de Transformación

La fase de transformación es el punto crítico donde se garantiza la calidad del dato antes de que llegue a los modelos de aprendizaje automático. Para que los resultados que arroje el modelo sean válidos y útiles para la toma de decisiones esta fase es de vital importancia (Basura entra - Basura sale).

- **Validación de Completitud:** Se verifica que no existan huecos temporales en la serie de 15 minutos. Si falta una lectura, se aplica un algoritmo de imputación lineal basado en el histórico del mismo ID_Cliente.
- **Control de Consistencia Lógica:** Se cruza el dato de consumo con la Potencia_Contratada. Si el consumo detectado supera la potencia técnica del punto de suministro, el dato se marca para revisión por sospecha de fallo en el sensor o fraude.
- **Normalización de Formatos:** Conversión de unidades (ej. de Wh a kWh) y ajuste de zonas horarias al estándar UTC para asegurar que los datos meteorológicos y de consumo estén perfectamente alineados en el tiempo.
- **Validación de Integridad Referencial:** Se comprueba que cada Meter_ID entrante exista realmente en la tabla Mapa_Contadores del silo técnico.

2.3. Políticas de Regulación del Ciclo de Vida

Para gobernar el uso de los datos, se han establecido las siguientes políticas y acciones a realizar en cada etapa del ciclo de vida del dato:

Etapa	Política de Uso
Ingesta	● [PL01] Solo se permite la entrada de datos desde dispositivos con certificado digital válido. ● [PL02] Se prohíbe la modificación del dato original.
Transformación	● [PL03] Los procesos de limpieza deben dejar rastro en un log de auditoría. ● [PL04] Está prohibido eliminar datos. ● [PL05] Los datos erróneos o incompletos se moverán a una zona de cuarentena para revisiones futuras.
Almacenamiento	● [PL06] Los datos de consumo deben encriptarse en reposo. ● [PL07] Se establece una política de retención de 5 años (Si es posible según leyes).
Explotación	● [PL08] Solo los perfiles autorizados de la empresa podrán acceder a la información crítica (como los perfiles de clientes). ● [PL09] No se permite la descarga de datos en dispositivos locales no corporativos.